Fiche technique — DressMe Objectif 5 (reproduction)

Oct 28, 2026 · @Ahmed Ayari

Cette fiche permet de reproduire l'agent de profilage de style (objectif DS 5) de bout en bout sur Colab, et d'expliquer chaque technique utilisée.

1. Prérequis

Il faut un compte Google, les deux archives du dataset dans Drive et un runtime Colab avec GPU T4. Compte environ 1 h 30 pour un run complet.

Élément	Détail
Notebook	`DressMe_Obj5_Agent_Profilage_Style_commente.ipynb` (dernière version corrigée)
Images	`Mon Drive/DressMe/Re-PolyVore.zip` : ≈ 127 000 images rangées en 20 dossiers par catégorie, nommées `<set_id>_<index>.jpg`
Métadonnées	`Mon Drive/DressMe/polyvore.tar.gz` : nom, prix, likes et split de chaque article (dataset Maryland). S'il manque, le notebook le récupère sur GitHub.
Runtime	Colab gratuit, Exécution > Modifier le type d'exécution > **T4 GPU**
Durée	CLIP ≈ 5 min, QLoRA ≈ 25 min, Prompt Tuning ≈ 20 min, évaluations ≈ 40 min

Attention : le nom exact du zip est `Re-PolyVore.zip`, avec un V majuscule. Si les fichiers ont été partagés avec toi, ajoute un raccourci dans `Mon Drive/DressMe` (clic droit > Organiser > Ajouter un raccourci). Sinon, le notebook ne les voit pas.

Garde l'onglet Colab ouvert pendant tout le run. Si la session coupe, tout ce qui est en mémoire est perdu, sauf ce qui a été sauvegardé dans Drive.

2. Étapes de reproduction

Le notebook s'exécute dans l'ordre, avec Exécution > Tout exécuter. Le tableau indique ce que fait chaque bloc et ce qu'il faut vérifier à l'écran avant de continuer.

Cellules	Section	Ce qu'elle fait	À vérifier
1-2	Installation	Installe les bibliothèques, définit `CFG`, seed = 42	Pas d'erreur pip
3	Drive	Monte Drive, décompresse le zip dans `/content/repolyvore`	« Extrait dans … »
4-5	Chargement	Relie chaque image à ses métadonnées par `(set_id, index)`	Jointure ≈ 99 %, splits train / valid / test
6	Nettoyage	Garde 4 000 outfits, catégorie simple, couleur, prix en DT	« prix connu » > 90 %
7	EDA	Graphiques catégories, couleurs, prix ; part d'articles homme	Trois graphiques
8-10	CLIP	Embeddings image + texte, style / saison / couleur en zero-shot	« Embeddings (≈ 25 000, 512) »
11-12	Clustering	PCA 64 + K-Means, choix de k, HDBSCAN, carte UMAP	Tableau des k, noms des clusters
13-14	Profils	300 utilisateurs synthétiques, profil et persona	Un profil JSON affiché
15-16	Éval. profilage	Accuracy / F1 persona, stabilité, Recall@10, NDCG@10	Tableaux de métriques
17-18	Outils	Tool schema + exécuteur sécurisé	Les 2 derniers tests renvoient une erreur (normal)
19	LLM	Charge Qwen2.5-7B en 4 bits	VRAM ≈ 5,5 Go
20-23	Agent	Prompts, garde-fous, graphe LangGraph, démo	« Orchestrateur : langgraph » + 3 réponses
24-25	Éval. agent	480 conversations, évaluation avant fine-tuning	Tableau base minimal / complet
26-27	QLoRA	Entraînement, sauvegarde, réévaluation	Loss qui descend, ≈ 40 M paramètres entraînables

Cellules	Section	Ce qu'elle fait	À vérifier
28	Prompt Tuning	Entraînement, comparaison, rechargement de QLoRA	Tableau final à 4 lignes
29	Sécurité	9 attaques, ASR	ASR final
30	Gouvernance	Biais de prix, versions, rapport, model card	Fichiers dans `DressMe/obj5_outputs`

Conseil : après la cellule 26, copie l'adaptateur dans Drive (`/content/drive/MyDrive/DressMe/lora_adapter`). La version corrigée le fait déjà. Ne relance jamais la cellule 26 à moitié exécutée sans la protection `if not hasattr(MODEL, "peft_config")`, sinon LoRA est appliqué deux fois.

3. Techniques utilisées

Le principe central : les calculs (profil, persona, recommandations) sont faits par du code déterministe, et le LLM ne fait qu'appeler ces calculs et les expliquer. Ainsi, chaque chiffre affiché est vérifiable.

Technique	Ce que c'est	Pourquoi on l'utilise
CLIP (ViT-B/32)	Modèle qui transforme une image ou un texte en vecteur de 512 nombres	Comparer des vêtements par similarité cosinus
Zero-shot	Classer sans entraînement, en comparant l'image à des phrases (« a photo of a chic fashion item »)	Obtenir style, saison et couleur sans annotations
Lift	Diviser la probabilité d'un style par sa moyenne globale	Corriger le biais de CLIP qui voit « casual » partout
PCA	Réduire 512 dimensions à 64	Clustering plus rapide et plus stable
K-Means + silhouette	Regrouper les articles en k styles ; la silhouette choisit le meilleur k	Créer une taxonomie de styles
HDBSCAN	Clustering par densité, qui détecte aussi le bruit	Comparer avec K-Means
UMAP	Projection en 2D	Visualiser la carte des styles

Technique	Ce que c'est	Pourquoi on l'utilise
Profil de style	Moyenne des embeddings + statistiques (palette, prix, diversité, entropie)	Résumer une garde-robe
Scores de persona	Trois formules simples, la plus forte gagne ; écart < 0,08 = « mixte »	Détecter efficacité / économie / image
Re-ranking	Bonus ou malus selon le persona après le score cosinus	Personnaliser les recommandations
Quantification 4 bits (NF4)	Stocker les poids du LLM sur 4 bits	Faire tenir un 7B sur le GPU T4
Tool calling	Le LLM écrit un appel JSON `<tool_call>` que le code exécute	Le LLM n'invente pas les données
ReAct	Boucle réfléchir → appeler un outil → observer → répondre	Raisonnement traçable
Prompt engineering	Rôle, grounding, persona, contexte tunisien, few-shot, JSON structuré, défense anti-injection	Comportement fiable et évaluable
QLoRA	Petites matrices (LoRA) entraînées sur un modèle gelé en 4 bits	Adapter le LLM à moindre coût
Prompt Tuning	Apprendre 32 « tokens virtuels » placés avant le prompt	Comparaison PEFT très légère
Loss masquée	La loss ne compte que l'appel d'outil et la réponse finale	Ne pas apprendre à recopier le prompt
LangGraph	Graphe d'états : input_guard → agent ⇄ outils → output_guard	Orchestration claire et bornée
Garde-fous	Filtres en entrée et en sortie, JSON Schema, nettoyage des sorties d'outils	Sécurité contre injection, fuite, IDOR
Red teaming + ASR	Attaquer l'agent et mesurer le taux de succès des attaques	Prouver l'efficacité des protections

4. Hyperparamètres de référence

Ce sont les valeurs à garder pour obtenir des résultats comparables.

Bloc	Hyperparamètres
Données	4 000 outfits (split train), seed = 42, taux USD → DT = 3,0
Embeddings	CLIP ViT-B/32, fusion 0,7 image + 0,3 texte, normalisation L2
Clustering	PCA 64, K-Means k ∈ [6, 16], n_init = 10, choix par silhouette ; HDBSCAN min_cluster_size = 40
Utilisateurs	300 (100 par persona), 25 à 40 pièces, 20 % de bruit, split 80 / 20
Persona	marge « mixte » = 0,08
Re-ranking	efficacité : neutres +0,10, basiques +0,05 ; économie : percentile prix −0,15 ; image : cluster dominant +0,10
LLM	Qwen2.5-7B-Instruct, 4 bits NF4, double quantification, calcul fp16
Génération (agent)	greedy, repetition_penalty 1,05, max_new_tokens 384
Génération (créatif)	temperature 0,4, top_p 0,9, top_k 40, repetition_penalty 1,05
Agent	MAX_STEPS = 4, un outil par étape
QLoRA	r 16, alpha 32, dropout 0,05 ; modules q, k, v, o, gate, up, down
Entraînement QLoRA	lr 2e-4, cosine, warmup 3 % des pas, batch 1 × 8 (accumulation), 2 epochs, max_len 2048, paged_adamw_8bit, max_grad_norm 0,3, gradient checkpointing
Prompt Tuning	32 tokens virtuels, init TEXT, lr 3e-2, 2 epochs, même batch
Dataset fine-tuning	480 conversations (240 utilisateurs train × 2 questions), 90 / 10 train / validation
Évaluation agent	20 cas test, 6 types de questions

5. Problèmes déjà rencontrés

Les cinq erreurs ci-dessous sont déjà corrigées dans la dernière version du notebook. Si l'une réapparaît, c'est qu'une ancienne version est utilisée.

Erreur	Cause	Solution
`Zip introuvable`	Recherche sensible à la casse (`PolyVore` avec V majuscule)	Chemin exact `/content/drive/MyDrive/DressMe/Re-PolyVore.zip`
`Aucun format reconnu`	Le zip ne contient que des images rangées par dossier, sans JSON	Loader par dossiers + jointure avec `polyvore.tar.gz`
`'BaseModelOutputWithPooling' object has no attribute 'float'`	Nouvelle version de `transformers`	Appeler `clip.vision_model` / `clip.text_model` puis les projections
`unexpected keyword argument 'warmup_ratio'`	`warmup_ratio` supprimé dans `transformers` 5	`warmup_steps` calculé à 3 % des pas, arguments filtrés selon la version
`NameError: name 'USERS' is not defined` (ou autre variable)	Une cellule plus haut a planté ou le runtime a redémarré	Remonter à la première erreur rouge ; sinon Tout exécuter

Autres conseils :

- En cas d'erreur mémoire (OOM) sur le GPU, remplace `LLM_ID` par `Qwen/Qwen2.5-3B-Instruct` dans `CFG`.
- Si le temps manque, mets `RUN_PROMPT_TUNING = False` dans `CFG` (gain ≈ 20 min).
- Ne lance jamais le notebook en local sur un portable : un GPU de 4 Go de VRAM ne suffit pas pour le 7B.

6. Résultats à vérifier et limites

Un run réussi produit quatre tableaux de résultats et deux fichiers dans `Mon Drive/DressMe/obj5_outputs`.

- [ ] Tableau des k (silhouette, Davies-Bouldin, Calinski-Harabasz) et noms des clusters
- [ ] Métriques de profilage : accuracy et F1 du persona, stabilité, cohérence du cluster
- [ ] Recall@10 et NDCG@10 : « cosinus + persona » doit battre « popularité »
- [ ] Tableau agent à 4 lignes : base minimal, base complet, QLoRA, Prompt Tuning
- [ ] Tableau red teaming et ASR final
- [ ] Fichiers `obj5_report.json` et `MODEL_CARD.md`

Limites à connaître :

- Les utilisateurs sont synthétiques, car Polyvore n'a pas d'utilisateurs. L'accuracy du persona est donc une borne haute.
- Le dataset est majoritairement féminin, alors qu'Amine et Sami sont des personas masculins.
- Le taux USD → DT est une constante fixe, et les marques tunisiennes ne sont pas couvertes.
- Les réponses d'entraînement viennent de gabarits, ce qui limite la variété des formulations.