Fiche technique — DressMe (jury de tenues à partir de photos)

Oct 28, 2026 · version de travail : système v2 + évaluation v3

Cette fiche permet de reproduire le projet de bout en bout sur Colab (galerie de photos, perception, juges, arbitre, réparateur, puis évaluation contre un évaluateur humain) et d'expliquer chaque technique utilisée.

Le principe central : la perception et les règles sont du code déterministe, les LLM jugent et expliquent, et chaque résultat est comparé aux verdicts d'un humain avec des intervalles de confiance. Tout fonctionne avec des services gratuits.

1. Prérequis

Élément	Détail
Compte	Google (Drive + Colab)
Code	Mon Drive/dressme_v2/dressme/ : fichiers de la v2, plus les 5 fichiers du patch v3 (llm2.py, judges2.py, calibrate.py, metrics2.py, survey2.py) et rules.py version « politique » (elle contient combine_levels)
Notebooks	DressMe_v2.ipynb (construction du système) et DressMe_v3_evaluation.ipynb (évaluation)
Données	Mon Drive/dressme_data/ (créé automatiquement) : wardrobe/, truth.json, perception_clip.json, survey2/, survey3/, llm_cache_v3/, v3_logs/
Dataset	H&M (Hugging Face : einrafh/hnm-fashion-recommendations-data), photos lues une à une, sans téléchargement complet
Clés (Colab > Secrets, accès au notebook activé)	GEMINI_API_KEY (AI Studio, gratuite, avec vision) et LLM_API_KEY (Groq, gratuite, texte seul)
Runtime	CPU suffisant pour les juges ; GPU T4 utile seulement pour la perception CLIP

Élément	Détail
Durée	Non chronométrée : elle dépend des quotas gratuits (estimation : environ 1 h si aucun quota n'est épuisé)

Attention : garde l'onglet Colab ouvert. Si la session coupe, tout ce qui est en mémoire est perdu, sauf ce qui est sauvegardé dans Drive (photos, caches, journaux, questionnaires). Les appels LLM sont mis en cache : relancer une cellule coûte 0 token.

2. Étapes de reproduction

Partie A : construire le système (notebook v2)

Section	Ce qu'elle fait	À vérifier
0 Installation	Monte Drive, définit DRESSME_DATA (…/dressme_data)	Message « OK, données dans … »
1 Échantillonnage	Tire des photos H&M par type, les réduit à 512 px, écrit truth.json	≈ 331 pièces ; ne pas interrompre (truth.json est écrit à la fin)
3 Perception	CLIP ViT-B/32 décrit chaque photo en JSON	Les 3 premières descriptions correspondent aux photos ; perception_clip.json créé
4 Galerie	Menu Femme / Homme / Divided, cases à cocher	Miniatures visibles
5 Contexte	Température, pluie, occasion	Dictionnaire de contexte affiché
6 Candidats	Décrit 4 pièces par catégorie pour le réparateur	Nombre de pièces candidates
7 Jury	Règles, LLM, hybride, arbitre, réparateur	Verdict avec raisons par critère
8 Éval. perception	Accuracy catégorie et couleur contre truth.json	≈ 0,86 et ≈ 0,61

Partie B : questionnaire et annotation humaine

Étape	Ce qu'elle fait	À vérifier
Génération	build_survey_outfits (40 tenues Femme) ou build_stratified_survey (60 tenues, un tiers par verdict des règles), puis planches PNG	outfits.json, questionnaire.csv, dossier planches
Annotation	Widget : une planche, trois boutons (convient, à améliorer, déconseillé), sauvegarde à chaque clic dans questionnaire_<nom>.csv	40 (ou 60) réponses reconnues

Ne relance jamais la génération après avoir annoté : elle réécrit les tenues, et les réponses ne correspondraient plus.

Partie C : évaluation (notebook v3)

Numéros de cellules de la version actuelle du fichier (ils peuvent changer si tu ajoutes ou supprimes des cellules).

Cellule	Ce qu'elle fait	À vérifier
2	Configuration : SURVEY_DIRS (survey2 = développement, survey3 = test)	Chemins corrects
4	FallbackLLM : Gemini puis Groq	Modèle principal affiché et test {ok: True}
6	Charge les tenues annotées	Nombre de tenues et répartition humaine
8	Bras A : juge texte sur descriptions CLIP, 6 exemples	« N déjà faites, M à faire »
10	Bras B : descriptions produites par un modèle de vision	Pièces décrites
12	Bras C : juge visuel sur la planche	Tenues jugées
14	Qualité de perception : CLIP contre modèle de vision	Tableau par catégorie
16	Tableau comparatif : accuracy, QWK, IC, biais	Une ligne par juge

Cellule	Ce qu'elle fait	À vérifier
18	Tests appariés (McNemar, delta de QWK)	Table des différences
20	Sauvegarde du tableau en CSV	Fichier créé
49	Baselines	Accuracy de la classe la plus fréquente
62 à 72	Pistes, analyse d'erreurs, contrôle des pièces	Liste des erreurs, pièces fausses

3. Techniques utilisées

Technique	Ce que c'est	Pourquoi on l'utilise
CLIP (ViT-B/32)	Modèle vision-langage à deux encodeurs (un Vision Transformer pour l'image, un Transformer pour le texte), entraîné par apprentissage contrastif ; il mesure la ressemblance entre une photo et des phrases	Décrire les photos gratuitement, sans quota
Zero-shot par phrases	Phrases du type « a photo of … » comparées à la photo : 29 types, puis 22 couleurs (avec le type trouvé dans la phrase), puis 3 motifs	Classer sans annotations
Table type vers formalité et chaleur	Valeurs de 1 à 5 associées à chaque type reconnu	CLIP ne lit pas ces deux attributs sur la photo
Juge à règles	Système expert : 4 critères notés de 0 à 2, puis combinaison	Transparent, gratuit, point de comparaison
Juge LLM (styliste)	Un LLM note les 4 critères avec une raison par critère	Nuance et justification

Technique	Ce que c'est	Pourquoi on l'utilise
Prompt engineering	Rôle, repères chiffrés par niveau, raison avant le niveau, 6 exemples de jugements humains en leave-one-out, format JSON imposé, prompt compact (≈ 600 tokens)	Réponses stables et évaluables
Sortie structurée (tool schema)	JSON mode + schéma décrit dans le prompt + validation par le code (niveau borné à 0-2, critère manquant = erreur) ; pas de function calling : les outils (météo, perception, règles, réparateur) sont appelés par le code	Fiabilité, coût, sécurité
Juge hybride (v2)	Le LLM reçoit l'avis détaillé des règles et ne peut le corriger que pour une raison précise	Combiner règles et LLM
Juge visuel (v3)	Un modèle multimodal juge la planche que l'humain a vue, sans description intermédiaire	Isoler l'effet des erreurs de perception
Arbitre	Médiane ordinale des niveaux des juges (repli : le plus prudent)	Verdict final simple, désaccords signalés
Réparateur	Recherche locale : retirer, remplacer ou ajouter UNE pièce, notée par les règles puis revérifiée par le jury	Correction minimale
Orchestration	Pipeline Python déterministe ; FallbackLLM (modèle de secours), cache disque, journal JSONL reprenable (run_batch), plafond de tokens par minute	Quotas gratuits et reprise après coupure
Fine-tuning	Aucun : CLIP en zero-shot, LLM en few-shot	Trop peu d'étiquettes (40 à 100), risque de sur-apprentissage

Technique	Ce que c'est	Pourquoi on l'utilise
Évaluation	Accuracy, accuracy équilibrée, macro-F1, QWK, MAE, biais, Spearman, matrices de confusion, baseline, bootstrap 2 000 tirages, test de McNemar, calibration en leave-one-out	Mesurer sans se tromper de conclusion
Sécurité	Clés dans les Secrets Colab, aucun texte libre d'utilisateur envoyé au LLM, vocabulaires fermés validés par le code, photos de catalogue uniquement, tenue testée exclue des exemples	Limiter injection, fuite et triche d'évaluation

Rôle des agents

Agent	Type	Rôle
Perception	CLIP (variante : Gemini vision)	Photo vers description JSON
Juge règles	Code	Quatre critères avec seuils explicites
Juge LLM	LLM	Jugement de styliste avec raisons
Juge hybride	LLM + règles	Confirme ou corrige l'avis des règles (v2 seulement)
Juge visuel	Modèle multimodal	Juge la planche (v3, comparaison)
Arbitre	Code	Médiane des verdicts
Réparateur	Code	Une seule modification proposée

Les 4 critères sont : couleurs, formalité (adéquation à l'occasion et entre les pièces), météo (chaleur et pluie), cohérence (tenue complète, sans doublon absurde). Niveaux : 2 = convient, 1 = à améliorer, 0 = déconseillé.

4. Hyperparamètres de référence

Valeurs à garder pour obtenir des résultats comparables.

Bloc	Hyperparamètres
Données	H&M, groupes Ladieswear / Menswear / Divided ; 23 types réduits à 7 catégories ; 331 pièces (12 types à 20 photos, 1 à 11, 10 à 8) ; miniatures 512 px, JPEG qualité 90 ; graine 0
Perception CLIP	openai/clip-vit-base-patch32 ; 29 types, 22 couleurs, 3 motifs ; choix par argmax ; résultats en cache JSON
Perception par modèle de vision (variante)	Image agrandie à 256 px minimum ; envoi en JPEG, côté max 1 024 px ; vocabulaire fermé
Contextes du questionnaire	7 combinaisons : 8 °C travail, 14 °C pluie décontracté, 22 °C décontracté, 30 °C soirée, 18 °C cérémonie, 5 °C pluie travail, 26 °C sport
Questionnaires	survey2 : 40 tenues Femme (graine 1) ; survey3 : 60 tenues, un tiers par verdict des règles (graine 11, T101 à T160) ; un évaluateur, trois niveaux
Règles (version politique)	Chaleur requise : 5 °C 4,5 ; 10 °C 4,0 ; 15 °C 3,2 ; 20 °C 2,5 ; 25 °C 1,8 ; au-delà 1,2. « Frais » sous 15 °C ; écart de chaleur toléré 1,0 ; 4 couleurs vives ou plus = 0 ; un critère à 0 suffit pour déconseillé ; un seul critère à 1 toléré pour convient
LLM v2	gpt-oss-20b via Groq, température 0, reasoning_effort low, mode JSON, pause de 8 s entre tenues
LLM v3	gemini-3.5-flash-lite (secours gemini-3.1-flash) ; Groq gpt-oss-120b puis gpt-oss-20b, reasoning_effort medium, 8 000 tokens par minute ; température non imposée ; mode JSON ; 6 essais, attente max 120 s ; cache SHA-256 ; environ 900 tokens en entrée et 120 en sortie par appel
Exemples du prompt	k = 6 (k = 12 testé), classes équilibrées, même occasion en priorité, tenue testée toujours exclue
Arbitre	median_low des niveaux ; si un juge échoue, le minimum des restants

Bloc	Hyperparamètres
Réparateur	Une modification ; 3 propositions maximum ; distance = écart de formalité + écart de chaleur + 0,5 si la couleur change
Évaluation	Bootstrap 2 000 tirages, IC à 95 %, test de McNemar exact, bootstrap apparié sur le delta de QWK, leave-one-out pour les calibrations

5. Problèmes déjà rencontrés

Erreur	Cause	Solution
404 NOT_FOUND sur gemini-2.5-flash	Modèle retiré pour les nouveaux comptes	Utiliser un modèle actuel (gemini-3.5-flash-lite)
429 RESOURCE_EXHAUSTED (limite de 20 requêtes par jour)	Quota gratuit par modèle	Cache, modèle de secours, reprise le lendemain, ou facturation
SecretNotFoundError	Secret absent ou accès au notebook désactivé	Créer le secret, activer l'accès, ou retirer la ligne Gemini
Photos ou truth.json introuvables	DRESSME_DATA pointait vers un autre dossier (dressme_data_hm)	Un seul dossier de données
Galerie avec des « ? »	truth.json écrit à la fin d'une cellule interrompue	Reconstruire truth depuis les photos déjà téléchargées
Widgets invisibles	Gestionnaire de widgets de Colab	enable_custom_widget_manager et menu déroulant
AttributeError : perceive_many	Corrections collées au milieu de la classe	Garder la méthode dans la classe
Anciennes descriptions après changement de la table de types	Cache perception_clip.json périmé	Supprimer le cache
Chiffres NaN, « No entries »	questionnaire.csv vide, 0 réponse	Pointer FILES vers le CSV annoté

Erreur	Cause	Solution
Questionnaire écrasé	Relance de la génération (rmtree ou save_survey)	Ne jamais relancer la génération après annotation
Session coupée	Inactivité ou quota GPU	Runtime CPU pour les juges ; caches et journaux
ImportError : combine_levels	rules.py ancien, ou module en mémoire	Remplacer rules.py et redémarrer la session
KeyError sur « règles | pire critère »	Colonne renommée dans le tableau	Garder les noms d'origine
NameError : agg ou niveau	Cellule d'outils placée trop bas	La placer juste après le chargement des tenues
KeyError sur cmp (graphiques)	Cellule lancée avant celle qui la définit	Respecter l'ordre des cellules

6. Résultats à vérifier et limites

Valeurs lues dans les sorties de tes notebooks. Elles peuvent varier si tu relances avec d'autres données ou d'autres modèles : cite toujours ce que ton notebook affiche.

Résultat	Valeur	Où le lire
Perception : catégorie	accuracy 0,861 (IC 0,825 à 0,897), macro-F1 0,83, rappel des robes 0,35	v2 section 8, sortie « CATÉGORIE »
Perception : couleur	0,609 (IC 0,561 à 0,664) ; méthode par pixels 0,588	v2 section 8, sortie « COULEUR »
Juges sur survey2 (v2)	règles 0,60 ; LLM 0,60 ; hybride 0,55 ; arbitre 0,55 ; baseline 0,475	v2, tableau « juge, n, accuracy »
Accord corrigé (kappa pondéré)	règles 0,459 ; LLM 0,475 ; hybride et arbitre 0,365	même tableau
Biais du LLM	−0,35 (plus sévère que l'humain)	même tableau
Désaccord entre les 3 juges	0,40 des tenues	v2, ligne « Désaccord entre juges »

Résultat	Valeur	Où le lire
Bras A sur survey2 (v3)	accuracy 0,675, QWK 0,625 (IC 0,39 à 0,80), choisi parmi 12 variantes : optimiste	v3 cellule 16
Bras B et C sur survey2	0,475 et 0,525	v3 cellule 16
Bras A contre ancien jury	delta de QWK +0,26 (IC 0,06 à 0,45, p = 0,012)	v3 cellule 18
Même configuration sur survey3 (test neuf)	environ 0,28 (17 tenues sur 60)	v3 analyse d'erreurs
Contrôle des pièces	23 pièces sur 101 mal décrites ; accuracy 0,33 sur les tenues sans erreur contre 0,25 avec	v3 cellules 70 à 72
Réparateur	87 % des tenues ratées reçoivent une proposition, 39 % passent à convient	v2 : mesure circulaire (les règles notent leurs propres corrections)

Limites à connaître

- Un seul évaluateur humain : pas de plafond de référence (accord entre humains inconnu).
- Peu de tenues (40 puis 60) : l'IC à 95 % d'une accuracy est d'environ ± 0,12 à ± 0,15.
- Le meilleur score de survey2 est optimiste ; sur survey3 il s'effondre. Le chiffre final doit venir d'un jeu neuf (survey4), annoté après avoir figé les règles.
- Les règles de la version politique ont été écrites après avoir vu les erreurs de survey2 et survey3 : elles n'ont pas encore été mesurées sur un jeu indépendant.
- 23 % des pièces sont mal décrites (surtout robes, noir lu comme bleu marine, doudoune ou manteau mal reconnus).
- La formalité et la chaleur viennent d'une table par type, pas de la photo.
- Les tenues du questionnaire sont tirées au hasard ; la classe convient est rare (4 sur 40).
- Dataset : catalogue H&M 2018-2020, peu représentatif de la mode tunisienne actuelle ; vérifier les conditions d'utilisation avant publication.
- En palier gratuit, Google peut réutiliser le contenu envoyé : n'envoie pas de photos personnelles.

7. Comparaison des versions

Version	Contenu	Résultat clé
v1	Garde-robe en JSON écrit à la main	Pas de mesure
v2	Vraies photos H&M, perception CLIP, jury à 3 juges, arbitre, réparateur	Premier questionnaire : accuracy 0,45, kappa 0,008 ; survey2 : 0,55 à 0,60
v3	Évaluation outillée : bras A, B, C, exemples en leave-one-out, IC, tests appariés, calibration, survey3	Bras A à 0,675 sur survey2 (optimiste) ; environ 0,28 sur survey3
Suite	Règles figées, survey4 annoté, second évaluateur	À mesurer